МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

РАБОТА ДОПУЩЕНА К ЗАЩИТЕ

Руководитель
программы _____ Ш.Г. Магомедов

«30» мая 2025 г.

ИТОГОВАЯ АТТЕСТАЦИОННАЯ РАБОТА

по дополнительной программы профессиональной переподготовки
«Программные средства решения прикладных задач искусственного интеллекта»

На тему: «Модель распознавания вариант XXX»

Обучающийся _____ Иванов Иван Иванович____
Подпись *Фамилия, имя, отчество*

группа XXXX-XX-XX

Руководитель работы _____ Ш.Г. Магомедов
подпись

Москва 2025 г.

ФИО: Новиков Максим Петрович
Группа: БСБО-05-21 (или БСБО-05-23, уточните правильный номер!)
Индивидуальная тема итоговой работы: Исследование и сравнение методов машинного обучения для задачи распознавания именованных сущностей в новостных текстах на английском языке (на основе датасета CoNLL-2003)

Введение

Актуальность темы

Распознавание именованных сущностей (Named Entity Recognition, NER) является одной из ключевых и активно развивающихся задач в области обработки естественного языка (Natural Language Processing, NLP). В условиях стремительного роста объемов текстовой информации, генерируемой в различных сферах, способность автоматически извлекать структурированные данные, такие как имена людей, названия организаций, географические локации и другие типы сущностей, приобретает первостепенное значение. Эффективные NER-системы находят применение в широком спектке приложений, включая информационный поиск, машинный перевод, создание систем ответов на вопросы, анализ социальных медиа, извлечение знаний из научных публикаций и бизнес-аналитику.

Несмотря на значительные успехи, достигнутые в области NER, задача остается актуальной из-за сложности естественного языка, многозначности слов, наличия новых и редких сущностей, а также специфики различных предметных областей и языков. Постоянное развитие методов машинного обучения, в частности глубокого обучения и трансформерных архитектур, открывает новые возможности для повышения точности и робастности NER-систем. Исследование и сравнение эффективности различных подходов на стандартных бенчмарках, таких как CoNLL-2003, позволяет не только оценить текущее состояние технологий, но и выявить наиболее перспективные направления для дальнейшего развития. Таким образом, актуальность данной работы обусловлена как теоретической значимостью задачи NER, так и ее высокой практической востребованностью в современных информационных системах.

Цель и задачи исследования

Цель исследования: Провести комплексное исследование и сравнительный анализ эффективности различных методов машинного обучения для решения задачи распознавания именованных сущностей в англоязычных новостных текстах на примере стандартного датасета CoNLL-2003.

Задачи исследования:

1. Провести обзор предметной области распознавания именованных сущностей, включая основные подходы, используемые метрики качества и существующие проблемы.
2. Выполнить анализ существующих моделей и решений для задачи NER, с акцентом на методы, показавшие высокую эффективность на датасете CoNLL-2003 или аналогичных задачах.

3. Описать процесс подготовки и предварительной обработки данных из датасета CoNLL-2003, выполненный в рамках технологической практики, и подготовить данные для экспериментов.
4. Реализовать, обучить и настроить несколько моделей машинного обучения для задачи NER, включая классический подход (Conditional Random Fields, CRF), нейросетевую архитектуру (Bi-LSTM-CRF) и современную модель на основе трансформеров (например, BERT).
5. Провести серию вычислительных экспериментов для оценки качества реализованных моделей на тестовой выборке датасета CoNLL-2003 с использованием стандартных метрик (Precision, Recall, F1-score).
6. Выполнить сравнительный анализ полученных результатов, выявить сильные и слабые стороны каждого из подходов и сформулировать выводы об их применимости и эффективности.

Объект и предмет исследования

- **Объект исследования:** Процесс распознавания именованных сущностей в англоязычных новостных текстах.
- **Предмет исследования:** Методы машинного обучения (включая Conditional Random Fields, рекуррентные нейронные сети с CRF-слоем и модели на основе архитектуры трансформер) и их сравнительная эффективность применительно к задаче распознавания именованных сущностей на датасете CoNLL-2003.

Структура работы

Данная выпускная квалификационная работа состоит из введения, трех основных глав, заключения, списка литературы и приложений.
Во **введении** обосновывается актуальность выбранной темы, формулируются цель и задачи исследования, определяются объект и предмет исследования, а также приводится краткое описание структуры работы.
Первая глава, **"Аналитический обзор"**, посвящена теоретическим аспектам задачи распознавания именованных сущностей. В ней рассматривается предметная область, анализируются существующие подходы и модели, а также описывается используемый набор данных и его подготовка.
Вторая глава, **"Проектная часть"**, содержит описание процесса разработки и исследования моделей машинного обучения. Здесь подробно излагается постановка задачи обучения, выбор и обоснование архитектур моделей, процесс их обучения или дообучения, а также методика проведения экспериментов и детальный анализ полученных результатов.
В **заключении** подводятся итоги всей проделанной работы, формулируются основные выводы, оценивается степень достижения поставленных целей и намечаются перспективы дальнейших исследований в данной области.
Список литературы включает перечень использованных научных статей, монографий и электронных ресурсов.
В **приложениях** могут быть представлены листинги разработанного программного кода, подробные таблицы с результатами экспериментов и другие вспомогательные материалы.

Глава 1. Аналитический обзор

1.1. Обзор предметной области

Распознавание именованных сущностей (Named Entity Recognition, NER) является одной из фундаментальных подзадач извлечения информации (Information Extraction) и обработки естественного языка (Natural Language Processing, NLP). Основная цель NER заключается в локализации и классификации атомарных элементов текста по предопределенным категориям, таким как имена людей, названия организаций, географические объекты (города, страны), даты, денежные суммы, процентные соотношения и другие типы именованных сущностей.

Исторически, первые подходы к NER основывались на правилах, создаваемых вручную лингвистами, и использовании больших словарей и газеттиров. Такие системы часто демонстрировали высокую точность на узкоспециализированных доменах, но требовали значительных трудозатрат на разработку и плохо переносились на новые области или языки.

С развитием машинного обучения получили распространение статистические методы, такие как Скрытые Марковские Модели (Hidden Markov Models, HMM), Метод Максимальной Энтропии (Maximum Entropy, MaxEnt), Метод Опорных Векторов (Support Vector Machines, SVM) и Условные Случайные Поля (Conditional Random Fields, CRF). Эти подходы рассматривают NER как задачу последовательной разметки, где каждому токену в предложении присваивается метка, указывающая на его принадлежность к определенному типу сущности или на то, что он не является частью сущности.

Для представления границ многословных сущностей широко используется схема разметки IOB (Inside, Outside, Beginning), где 'B-ТИП' обозначает начало сущности типа ТИП, 'I-ТИП' – токен внутри сущности типа ТИП, а 'O' – токен вне какой-либо сущности. Иногда используются более детализированные схемы, такие как IOBES (добавляются E-ТИП для конца сущности и S-ТИП для однословной сущности). В датасете CoNLL-2003, используемом в данной работе, применяется стандартная IOB-разметка.

Ключевыми вызовами в задаче NER являются разрешение лексической неоднозначности (одно и то же слово может быть сущностью в одном контексте и не быть ею в другом, или относиться к разным типам сущностей), распознавание новых или редких сущностей, отсутствующих в обучающих данных, а также обработка сложных и вложенных структур сущностей.

1.2. Анализ аналогичных моделей/решений

Для решения задачи распознавания именованных сущностей (NER) было предложено множество различных подходов, основанных на машинном обучении. На стандартном датасете CoNLL-2003, который является одним из основных бенчмарков для NER на английском языке, исследователи протестировали широкий спектр моделей, и их результаты служат ориентиром для новых исследований. Общий обзор технологий и инструментов для NER, включая современные подходы, можно найти в работах[1][2][3][4][5].

Классические статистические модели: Условные Случайные Поля (Conditional Random Fields, CRF) долгое время считались одними из наиболее эффективных статистических методов для NER[6][7][8][9]. В основополагающей работе Лафферти, МакКаллума и Перейры (Lafferty, McCallum, & Pereira, 2001) [ссылку на оригинальную статью по CRF, если найдете, или оставьте эту], где и были предложены CRF, подчеркивалась их способность моделировать условную вероятность последовательности меток при заданных наблюдениях. Это делает их особенно подходящими для задач разметки последовательностей, таких как NER. В последующих работах, например, применительно к CoNLL-2003, CRF с тщательно подобранными признаками (лексическими, орфографическими, контекстными, POS-тегами, чанк-тегами) достигали высоких показателей, часто в диапазоне **88-89% по F1-мере**. Основным преимуществом CRF является их способность учитывать зависимости между соседними метками в последовательности. Исследования по применению CRF для русскоязычных текстов также подтверждают эффективность этого метода, например, в работах Авериной М.Д. и Левановой О.А. (2023)[10] и в обзорах, упоминающих применение CRF для русского языка[11][12].

Нейросетевые подходы: С развитием глубокого обучения значительную популярность приобрели нейросетевые архитектуры, особенно рекуррентные нейронные сети (RNN). Архитектура Bi-LSTM-CRF (двунаправленная LSTM с последующим CRF-слоем) стала стандартом де-факто для NER. В работе Лампля и его соавторов (Lample et al., 2016)[13][14][15][16] такая модель, использующая векторные представления слов и символьные эмбеддинги, на датасете CoNLL-2003 для английского языка достигла **F1-меры 90.94%**. Аналогично, Чиу и Николс (Chiu & Nichols, 2016)[17][18][19][20][21], комбинируя сверточные слои для извлечения признаков символьного уровня с Bi-LSTM, добились **F1-меры 91.62%** на том же датасете CoNLL-2003 (при использовании дополнительных лексиконов). Преимущество таких моделей заключается в автоматическом извлечении признаков и способности улавливать длинные контекстные зависимости. Работы по применению Bi-LSTM-CRF для русского языка также демонстрируют высокую эффективность [35, 42 (для мультизадачного обучения)]. В работе Кульневича и др. (2022)[22] рассматривается комбинация Bi-LSTM и CRF для распознавания технологических терминов в условиях ограниченной выборки.

Модели на основе трансформеров: В последние годы доминирующее положение в NLP, включая NER, заняли модели на основе архитектуры Трансформер, такие как BERT (Devlin et al., 2018)[23][24][25][26][27]. BERT предварительно обучается на огромных текстовых корпусах, что позволяет ему формировать богатые контекстуализированные представления слов. Для задачи NER BERT обычно дообучается (fine-tuning) путем добавления классификационного слоя. В оригинальной статье Devlin et al.[23] модель BERT-Large, дообученная на CoNLL-2003, достигла **F1-меры 92.8%**. На платформе Hugging Face можно

найти множество предобученных и дообученных на CoNLL-2003 моделей BERT для NER, например, dslim/bert-base-NER[28][29] или Hatman/bert-finetuned-ner[30], которые показывают сравнимые или даже лучшие результаты (например, модель sfarrukhm/bert-conll-ner[31] заявляет F1-score 94.32% на тестовом наборе CoNLL-2003). Обзоры и туториалы также подчеркивают эффективность BERT для NER[32][33]. Применение BERT для извлечения именованных сущностей из русскоязычных текстов также является актуальной задачей, как отмечено в работе Шагиздановой и Тулупьева (2020)[34]. NLP-progress[35] также является хорошим ресурсом для отслеживания SOTA результатов на CoNLL-2003, где упоминаются и BERT-подобные модели с F1 выше 94%.

1.3. Описание подготовленных данных

В данной выпускной квалификационной работе используется стандартный датасет CoNLL-2003, предназначенный для задачи распознавания именованных сущностей (Named Entity Recognition, NER) на английском языке. Подробный анализ и предварительная обработка данного датасета были выполнены в рамках технологической практики, результаты которой легли в основу подготовки данных для текущего исследования.

Источник и структура датасета:
Датасет CoNLL-2003 был предоставлен в рамках CoNLL-2003 Shared Task. Он состоит из новостных статей из Reuters Corpus. Данные разделены на три части: обучающую (eng.train), валидационную (eng.testa), используемую для настройки гиперпараметров моделей, и тестовую (eng.testb), предназначенную для итоговой оценки качества моделей.
Формат данных – текстовые файлы, где каждая строка представляет один токен с сопутствующей информацией (сам токен, его часть речи, чанк-тег и NER-тег), разделенной пробелами. Предложения разделены пустыми строками. NER-теги представлены в формате IOB.

Объем данных:

- Обучающая выборка: 14987 предложений (204567 токенов).
- Валидационная выборка: 3466 предложений (51578 токенов).
- Тестовая выборка: 3684 предложения (46666 токенов).

Анализ данных (ключевые моменты из отчета по практике):
В ходе разведочного анализа данных (EDA) были выявлены следующие ключевые характеристики:

- **NER-теги:** Используется 9 уникальных NER-тегов: 'O', 'B-PER', 'I-PER', 'B-ORG', 'I-ORG', 'B-LOC', 'I-LOC', 'B-MISC', 'I-MISC'. Наблюдается значительный дисбаланс классов с преобладанием тега 'O'. Среди именованных сущностей наиболее частыми являются B-LOC, B-PER и B-ORG. (Ссылка на График 1 из отчета по практике может быть здесь или график можно повторить в приложении).
- **Длины предложений:** Распределение длин предложений имеет право-скошенный характер. Средняя длина предложения в обучающей выборке составляет 13.65 токенов, медианная – 9.00 токенов,

максимальная – 113 токенов. (Ссылка на График 2 из отчета по практике или повтор графика).

- **Словарь:** Общее количество уникальных токенов во всем датасете составляет 30177.

Выполненные шаги предобработки данных:
На основе проведенного анализа для подготовки данных к использованию в моделях машинного обучения были выполнены следующие шаги:

1. **Преобразование тегов сущностей в числовые идентификаторы (ID):** Каждому уникальному NER-тегу был присвоен целочисленный идентификатор.
2. **Паддинг и усечение последовательностей:** Все последовательности токенов и соответствующих им тегов были приведены к единой максимальной длине MAX_SEQ_LENGTH = 128. Для более коротких последовательностей применялся паддинг специальным токеном [PAD] (и соответствующим тегом O), а более длинные (хотя в данном датасете таковых практически нет после выбора MAX_SEQ_LENGTH=128) были бы усечены.
3. **BERT-токенизация и выравнивание меток (для трансформерных моделей):** Для подготовки данных к моделям на основе трансформеров (например, BERT) была выполнена токенизация с использованием BertTokenizerFast из библиотеки transformers. Этот токенизатор разбивает слова на суб-единицы (subword tokens). Соответственно, был реализован механизм выравнивания оригинальных NER-меток с полученными суб-токенами, что является критически важным шагом для корректного обучения таких моделей.

Таким образом, данные были тщательно проанализированы и подготовлены, что создает необходимую основу для проведения экспериментов по обучению и сравнению различных моделей машинного обучения для задачи NER.