МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

ОТЧЁТ ПО ПРАКТИКЕ В ПРОФИЛЬНОЙ СФЕРЕ

Тема практики: «Подготовка и предварительная обработка данных предметной области для модели распознавания вариант 545»

Отчет представлен к рассмотрению:
Студент группы БСБО-05-21 «31» мая 2025 г. _____ Новиков М.П.
(подпись)

Отчет утвержден.
Допущен к защите:

Руководитель практики «31» мая 2025 г. _____ Магомедов Ш.Г.
(подпись)

Москва 2025 г.

МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

ИНДИВИДУАЛЬНОЕ ЗАДАНИЕ НА ПРАКТИКУ В ПРОФИЛЬНОЙ СФЕРЕ

Студенту 2 курса учебной группы БСБО-05-23
Новикову Максиму Петровичу

Время практики: с 26 мая 2025 г. по 31 мая 2024 г.
Должность на практике: студент

1. ЦЕЛЕВАЯ УСТАНОВКА: подготовка и предварительная обработка данных предметной области, а также формулировка аналитической задачи, решаемой с использованием технологий искусственного интеллекта

2. СОДЕРЖАНИЕ ПРАКТИКИ:

2.1 Обзор существующих решений и подходов к подготовке данных и построению моделей анализа в выбранной предметной области

2.2 Описание источников, структуры, характеристик и объема исходных данных, включая потенциальные проблемы качества данных и способы их устранения

2.3 Формулировка задачи анализа данных с указанием её целей, постановки в терминах машинного обучения, а также описание ожидаемого результата

3. ОРГАНИЗАЦИОННО-МЕТОДИЧЕСКИЕ УКАЗАНИЯ: в процессе практики рекомендуется использовать периодические издания и отраслевую литературу годом издания не старше 10 лет.

СОГЛАСОВАНО:
Руководитель практики
«26» мая 2025 г. _____ (Магомедов Ш.Г.)
(подпись)

Задание получил
«26» мая 2025 г. _____ (Новиков М.П.)
(подпись)

МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»

РТУ МИРЭА

РАБОЧИЙ ГРАФИК ПРОВЕДЕНИЯ
практики в профильной сфере

Студента Новикова М.П. 2 курса группы БСБО-05-23.

№	Сроки выполнения	Этап	Отметка о выполнении
1	26.05.2025	Подготовительный этап, включающий в себя организационное собрание (Вводная лекция о порядке организации и прохождения практики)	выполнено
2	с 26.05.2025 по 29.05.2025	Выполнение задания по практике в соответствии с выданным заданием студента. (Мероприятия по сбору, обработке и структурированию материала, выполнение поставленной задачи)	выполнено
3	с 29.05.2025 по 30.05.2025	Подготовка отчета по практике (Оформление материалов отчета в полном соответствии с требованиями на оформление учебных работ студентов)	выполнено
4	31.05.2025	Представление отчета по практике к защите посредством загрузки на портал ДПО (https://online-dpo.mirea.ru/)	выполнено

Согласовано:

Руководитель практики _____/ Магомедов Ш.Г. /

Обучающийся _____/ Новиков М.П. /

Содержание

1. Введение 5
1.1. Цель и задачи практики 5
1.2. Краткое описание предметной области 5
1.3. Обоснование актуальности работы 6
2. Основная часть 7
2.1. Обзор подходов и решений 7
2.2. Характеристика данных 8
2.3. Постановка задачи анализа данных для определения методов МО 11
3. Заключение 13
3.1. Общие выводы 13
3.2. Достижение поставленных целей 13
3.3. Возможные направления доработки или применения 13
4. Список литературы 15

Отчет по технологической практике

Тема: Исследование и сравнение методов машинного обучения для задачи распознавания именованных сущностей в новостных текстах на английском языке (на основе датасета CoNLL-2003)

1. Введение

1.1. Цель и задачи практики

Цель практики: Провести глубокое исследование и анализ датасета CoNLL-2003 для задачи распознавания именованных сущностей (NER), подготовить данные для экспериментальных работ и определить наиболее перспективные методы машинного обучения для их решения в рамках последующей Выпускной Квалификационной Работы (ВКР).

Задачи практики:

1. Загрузить и ознакомиться со структурой датасета CoNLL-2003.
2. Провести разведочный анализ данных (EDA), включая анализ распределения токенов, длин предложений и типов именованных сущностей.
3. Выполнить необходимую предобработку данных, включая преобразование тегов, паддинг/усечение последовательностей и токенизацию, совместимую с современными моделями машинного обучения (в частности, трансформерами).
4. На основе анализа данных сформулировать и обосновать гипотезы о применимости различных методов машинного обучения (CRF, нейросетевые архитектуры типа Bi-LSTM-CRF, модели на основе трансформеров) для решения задачи NER на данном датасете.

1.2. Краткое описание предметной области

Распознавание именованных сущностей (Named Entity Recognition, NER) является одной из фундаментальных задач обработки естественного языка (Natural Language Processing, NLP). Её суть заключается в идентификации и классификации именованных сущностей в тексте по предопределенным категориям. Стандартные категории включают имена людей (PER), названия организаций (ORG), географические местоположения (LOC) и прочие различные сущности (MISC).

Разметка данных для NER часто выполняется в формате IOB (Inside, Outside, Beginning), где 'B-' обозначает начало сущности, 'I-' – внутренний токен многословной сущности, а 'O' – токен, не являющийся частью какой-либо сущности. Данный подход позволяет точно определять границы и типы именованных выражений в тексте.

1.3. Обоснование актуальности работы

Задача распознавания именованных сущностей имеет высокую актуальность в современных NLP-системах. NER является ключевым компонентом для множества приложений, таких как информационный поиск, извлечение структурированных знаний из неструктурированного текста, машинный перевод, создание вопросно-ответных систем, анализ настроений и автоматическое реферирование. Точное и эффективное распознавание сущностей позволяет значительно улучшить качество и релевантность результатов этих систем.

Датасет CoNLL-2003, используемый в данной работе, является широко признанным стандартным бенчмарком для оценки и сравнения различных систем NER. Исследование и применение современных методов машинного обучения на этом датасете позволяет не только оценить их эффективность, но и внести вклад в развитие технологий обработки естественного языка. Потребность в более точных и робастных моделях NER постоянно растет по мере увеличения объемов текстовой информации и усложнения требований к ее автоматической обработке.

2. Основная часть

2.1. Обзор подходов и решений

Для выполнения анализа и подготовки данных в рамках данной технологической практики был использован следующий набор технологий, инструментов и библиотек:

1. **Язык программирования:** Python 3.x, выбранный благодаря своей популярности в области анализа данных и машинного обучения, а также наличию большого количества специализированных библиотек.
2. **Среда разработки:** Jupyter Notebook, интерактивная среда, позволяющая комбинировать код, текстовые описания и визуализации, что удобно для исследовательских задач.
3. **Библиотеки для анализа и манипуляции данными:**
   - pandas: для создания и анализа структурированных данных, в частности, для работы с сериями данных при подсчете частот тегов.
   - numpy: для эффективных численных вычислений и работы с массивами.
4. **Библиотеки для визуализации данных:**
   - matplotlib: фундаментальная библиотека для создания статических, анимированных и интерактивных визуализаций.
   - seaborn: надстройка над matplotlib, предоставляющая более высокоуровневый интерфейс для создания информативных и привлекательных статистических графиков.
5. **Специализированные NLP-библиотеки:**
   - transformers (от Hugging Face): для работы с предобученными моделями трансформеров, в частности, для использования токенизатора BertTokenizerFast для подготовки данных к подаче в модели типа BERT.
6. **Методики анализа данных:**
   - **Разведочный анализ данных (EDA):** Включал статистический анализ (подсчет частот, длин, вычисление средних, медианных значений) и визуальный анализ (построение гистограмм и столбчатых диаграмм для оценки распределений).
7. **Методики подготовки данных для NER:**
   - **Парсинг формата CoNLL:** Реализована функция для чтения данных из специфического формата CoNLL-2003.

- **Преобразование категориальных тегов в числовые идентификаторы:** NER-теги были отображены в числовые ID для их последующего использования в моделях.
- **Паддинг и усечение последовательностей:** Для приведения всех входных последовательностей к единой длине применялся паддинг (дополнение специальным токеном) и усечение.
- **Токенизация с учетом суб-слов и выравнивание меток:** Использовался BertTokenizerFast для разбиения текста на токены (включая суб-токены) и реализован механизм выравнивания NER-меток с полученными токенами, что критически важно для моделей на основе трансформеров.

2.2. Характеристика данных

В работе использовался датасет CoNLL-2003, который является стандартным ресурсом для задачи распознавания именованных сущностей на английском языке.

- **Источник данных:** Датасет был предоставлен в рамках CoNLL-2003 Shared Task: Language-Independent Named Entity Recognition.
- **Структура данных:** Данные представлены в текстовых файлах (eng.train, eng.testa для валидации, eng.testb для тестирования). Каждая строка файла соответствует одному токену и содержит информацию о самом токене, его части речи (POS-теге), чанк-теге и NER-теге, разделенных пробелами. Предложения отделены друг от друга пустыми строками.
- **Объем данных:**
  Обучающая выборка (eng.train): 14987 предложений, 204567 токенов.
  Валидационная выборка (eng.testa): 3466 предложений, 51578 токенов.
  Тестовая выборка (eng.testb): 3684 предложения, 46666 токенов.
- **Типы данных:**
  - Текстовые данные: токены (слова, знаки препинания).
  - Категориальные данные: NER-теги ('O', 'B-PER', 'I-PER', 'B-ORG', 'I-ORG', 'B-LOC', 'I-LOC', 'B-MISC', 'I-MISC').

Анализ NER-тегов:

Всего используется 9 уникальных NER-тегов. Распределение именованных сущностей (без учета тега 'O') представлено на Графике 1.

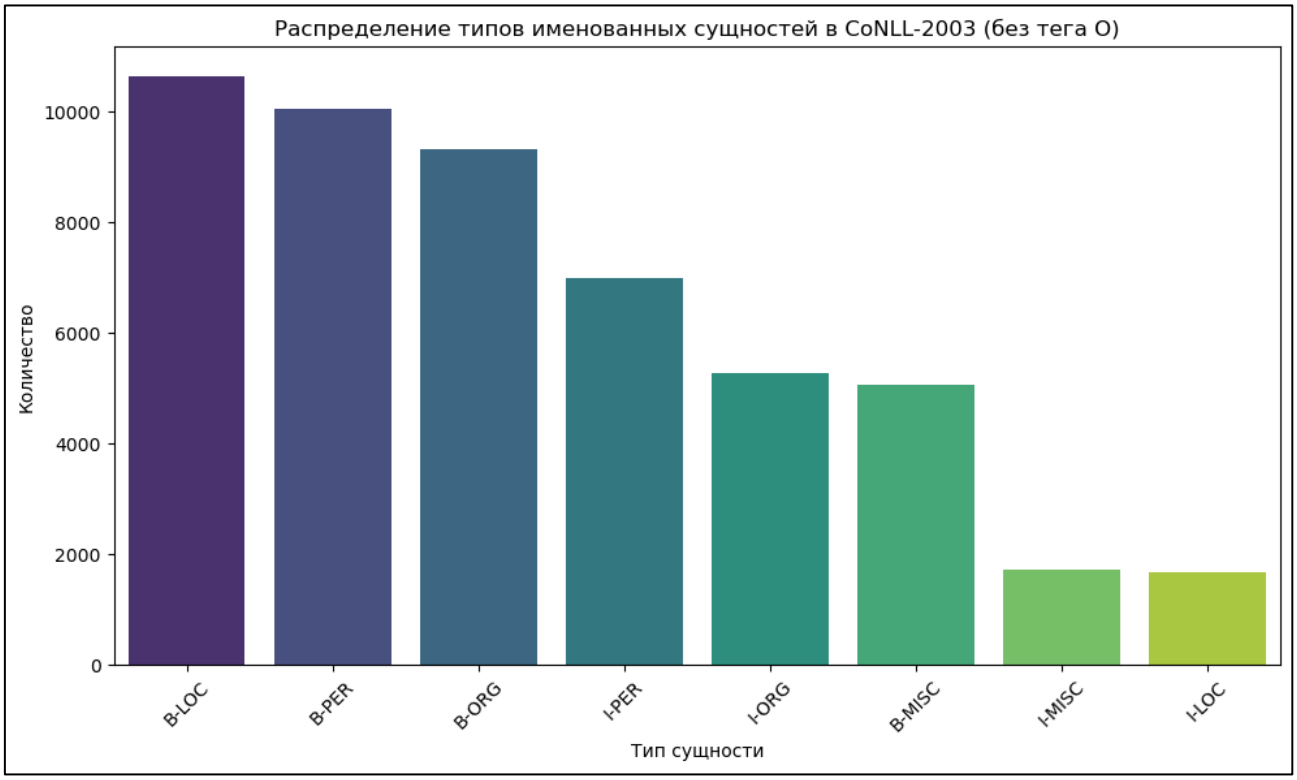

График 1

Наиболее частыми типами сущностей являются B-LOC (10645), B-PER (10059) и B-ORG (9323), а наименее частыми – I-MISC (1717) и I-LOC (1671). Анализ всех тегов показывает значительный дисбаланс классов: тег 'O' (не сущность) является преобладающим. Этот дисбаланс необходимо будет учитывать при обучении моделей, возможно, с помощью взвешенных функций потерь или специфических метрик.

Анализ длин предложений:

Распределение длин предложений для обучающей, валидационной и тестовой выборок представлено на Графике 2.

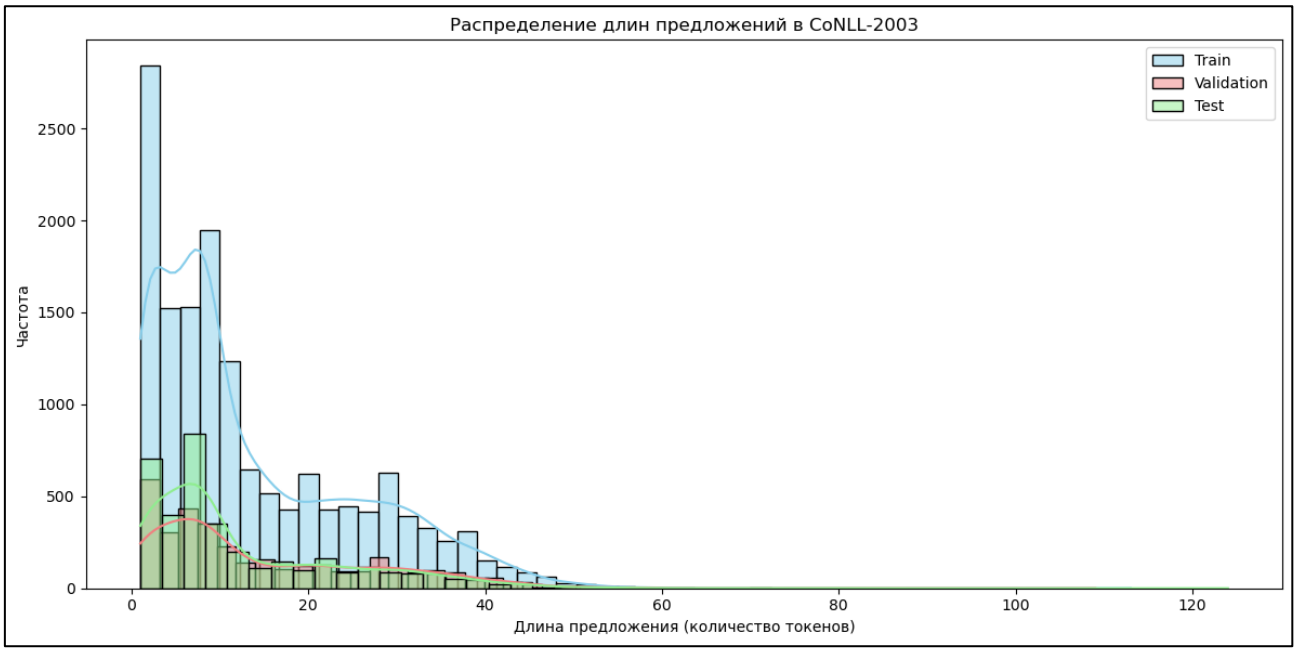

График 2

Оно показывает право-скошенное распределение с пиком в районе коротких предложений и длинным хвостом более длинных предложений. Для обучающей выборки: средняя длина предложения составляет 13.65 токенов, медианная – 9.00 токенов, а максимальная – 113 токенов. Выбранная максимальная длина последовательности MAX_SEQ_LENGTH = 128 покрывает практически все предложения (более 99.9% в обучающей выборке, так как максимальная длина 113 < 128) и является разумным компромиссом для моделей, требующих фиксированной длины входа.

Анализ словаря и токенов:

Общее количество уникальных токенов во всем датасете составляет 30177. Топ-20 самых частых токенов включают: [(',', 10876), ('.', 10874), ('the', 10672), ('of', 5426), ('in', 5073), ('to', 5067), ('a', 4414), ('(', 4226), (')', 4225), ('and', 4180), ("", 3239), ('on', 3041), ('said', 2690), ("'s", 2283), ('for', 2048), ('-', 1866), ('1', 1845), ('The', 1611), ('was', 1593), ('-DOCSTART-', 1393)]. Это в основном служебные слова, знаки препинания и наиболее общие слова английского языка.

Указание на проблемы и особенности данных:

1. **Дисбаланс классов NER-тегов:** Значительное преобладание тега 'O'.
2. **Вариативность длин предложений:** Требует применения паддинга для моделей с фиксированной длиной входа.

3. **Суб-токенная токенизация:** При использовании трансформерных моделей необходима специальная токенизация и выравнивание меток.

Датасет CoNLL-2003 является хорошо подготовленным эталонным набором данных, поэтому проблемы с пропусками, явным шумом или несоответствиями в разметке минимальны.

2.3. Постановка задачи анализа данных для определения методов МО

Задача распознавания именованных сущностей (NER) в терминах машинного обучения формулируется как задача **последовательной разметки (sequence labeling)**. Для каждого токена во входной последовательности (предложении) необходимо предсказать соответствующий NER-тег из предопределенного набора.

Цель анализа данных в рамках технологической практики заключалась не только в описании характеристик датасета, но и в том, чтобы на основе этих характеристик **обосновать выбор перспективных классов моделей машинного обучения** для их последующей реализации и сравнения в рамках ВКР.

Выполненные шаги предобработки:

На текущий момент выполнены следующие ключевые шаги предобработки, которые подготовили данные для использования в моделях:

1. **Преобразование тегов сущностей в ID:** Строковые метки NER преобразованы в числовые идентификаторы.
2. **Паддинг и усечение последовательностей:** Последовательности токенов и тегов приведены к единой максимальной длине (MAX_SEQ_LENGTH = 128).
3. **BERT-токенизация и выравнивание меток:** Данные токенизированы с использованием BertTokenizerFast, и метки NER выровнены с суб-единицами токенов BERT.

Гипотезы о методах МО для NER и их обоснование:

Учитывая последовательную природу задачи NER, характеристики датасета CoNLL-2003, выявленные в ходе EDA (распределение длин

предложений, дисбаланс тегов, анализ токенов), а также успешный опыт применения различных подходов, перспективными методами для сравнения являются:

1. **Conditional Random Fields (CRF):** Классический статистический метод, хорошо подходящий для задач разметки последовательностей. CRF моделируют условную вероятность последовательности тегов при условии входной последовательности токенов, явно учитывая зависимости между соседними тегами. Это соответствует природе задачи NER, где предсказание текущего тега зависит от предыдущих. CRF могут служить хорошей базовой моделью для сравнения.
2. **Рекуррентные нейронные сети (RNN) с LSTM/GRU и CRF слоем:** Модели на основе RNN (особенно с LSTM или GRU ячейками) способны эффективно обрабатывать последовательности и улавливать контекст. Добавление CRF слоя на выходной слой такой сети (архитектура Bi-LSTM-CRF) позволяет учитывать структурные зависимости между тегами на этапе декодирования, что часто улучшает качество разметки. Последовательная природа задачи NER и необходимость учета локального контекста (средняя длина предложения 13.65 токенов) делают модели типа Bi-LSTM-CRF перспективными.
3. **Модели на основе трансформеров (BERT, RoBERTa и др.):** Современные модели, такие как BERT, используют механизм внимания для улавливания как локальных, так и долгосрочных зависимостей в тексте, предоставляя мощные контекстуализированные эмбеддинги. Значительный размер словаря (30177 уникальных токенов), наличие редких слов и потенциальная важность долгосрочных зависимостей в тексте для корректного распознавания сущностей, а также успешное применение предобученных трансформерных моделей для NER в современных исследованиях, указывают на целесообразность использования моделей типа BERT. Проведенная токенизация с помощью BertTokenizerFast и выравнивание меток уже подготовили данные для этого подхода.

Результаты анализа данных и проведенной предобработки формируют основу для дальнейшей экспериментальной работы. Обоснованный выбор моделей позволяет сфокусировать усилия на наиболее перспективных направлениях для достижения высокого качества решения задачи NER.

3. Заключение

3.1. Общие выводы

В ходе технологической практики был проведен всесторонний анализ датасета CoNLL-2003 для задачи распознавания именованных сущностей. Были изучены его структура, объем, типы данных, распределение NER-тегов и длин предложений, а также выполнен анализ словарного состава.

Выявлены ключевые особенности датасета, такие как значительный дисбаланс классов NER-тегов (преобладание тега 'O') и вариативность длин предложений. Проведена необходимая предобработка данных, включающая преобразование тегов в числовые идентификаторы, паддинг и усечение последовательностей до единой длины, а также токенизацию и выравнивание меток для совместимости с моделями на основе трансформеров.

На основе проведенного анализа сформулированы и обоснованы гипотезы о перспективности использования методов CRF, Bi-LSTM-CRF и моделей на основе трансформеров (например, BERT) для решения поставленной задачи.

3.2. Достижение поставленных целей

Все цели и задачи, поставленные на технологическую практику, были успешно достигнуты:

- Датасет CoNLL-2003 загружен, его структура детально изучена.
- Проведен комплексный разведочный анализ данных, выявлены его основные характеристики и особенности.
- Выполнена необходимая предобработка данных, подготовившая их к использованию в моделях машинного обучения.
- На основе анализа данных определены и обоснованы перспективные методы машинного обучения для дальнейшего исследования в рамках ВКР.

Результаты технологической практики создают прочную основу для выполнения следующего этапа работы – разработки, обучения и сравнения моделей машинного обучения.

3.3. Возможные направления доработки или применения

Результаты данной практики будут непосредственно использованы в Выпускной Квалификационной Работе. Дальнейшие шаги включают:

1. Реализацию, обучение и настройку выбранных моделей машинного обучения (CRF, Bi-LSTM-CRF, модель на основе трансформера BERT) на подготовленном датасете CoNLL-2003.
2. Проведение сравнительного анализа производительности этих моделей с использованием стандартных метрик качества для задачи NER (Precision, Recall, F1-score).
3. Анализ ошибок моделей для выявления их сильных и слабых сторон и возможных путей улучшения.
4. Формулирование итоговых выводов об эффективности различных подходов к решению задачи распознавания именованных сущностей на данном датасете.

4. Список литературы

1. Sang, E. F., & De Meulder, F. (2003). Introduction to the CoNLL-2003 shared task: Language-independent named entity recognition. In *Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL 2003* (pp. 142-147).
2. Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*.
3. Lample, G., Ballesteros, M., Subramanian, S., Kawakami, K., & Dyer, C. (2016). Neural architectures for named entity recognition. *arXiv preprint arXiv:1603.01360*.
4. Документация библиотеки transformers от Hugging Face. [Электронный ресурс]. URL: https://huggingface.co/docs/transformers (дата обращения: 30.05.2025).
5. Документация библиотеки Seaborn. [Электронный ресурс]. URL: https://seaborn.pydata.org/ (дата обращения: 30.05.2025).